

Trotz dieser Stärken bestehen Grenzen. Die Studie untersucht KI- Rat nur im Kontext von (Un-)Ehrlichkeit, dabei werden keine organisatorischen Trade- Offs betrachtet. Die Generalisierbarkeit ist eingeschränkt, da die Studie nur ein eng umrissenes Laborszenario abbildet. Es bleibt unklar, ob ähnliche Effekte in realweltlichen moralischen Kontexten wie Steuern, Compliance oder Recruiting auftreten. Hinzu kommt, dass das verwendete Modell GPT-J nicht mehr State-of-the-Art ist. Neuere Modelle (z.B. GPT-4/5) könnten qualitativ andere oder stärkere Effekte hervorrufen (Liu *et al.*, 2023). Auch die fehlenden Informationen über das Anreizsystem der Ratgeber kann zu verzerrten Ergebnissen führen. Da GPT-J nur per Few-Shot-Learning angepasst wurde und nicht adaptiv reagiert, bleibt zudem offen, wie optimierende KI in realen Anwendungen oder über mehrere Beratungsrunden hinweg wirken würde. Das Screening der KI-Texte reduziert zudem externe Validität, da ungefilterte KI-Outputs im Alltag abweichen können (Dahlgren Lindström *et al.*, 2025).

Ein weiterer Kritikpunkt betrifft die einmalige Entscheidungssituation. Es bleibt unklar, ob wiederholte Interaktionen oder langfristige Dynamiken die Effekte verändern.

5 Entwurf eines empirischen Forschungsdesigns

Das Experimentdesign überträgt das bekannte Phänomen des KI-Einflusses auf moralisches Verhalten in einen realistischen und strategisch relevanten Kontext (Recruiting) und untersucht erstmals, wie KI- und menschliche Ratschläge ethische vs. ökonomische Zielkonflikte im Recruiting beeinflussen. Das Ziel des Forschungsdesigns besteht darin zu untersuchen, wie Ratschläge unterschiedlicher Art (ethik- vs. profitfördernd) und verschiedener Quellen (KI vs. Mensch) die Wahl zwischen zwei Bewerber:innen beeinflussen, die sich nur in ethischer Kompetenz und Kosten für das Unternehmen (Gehalt, Erfahrung) unterscheiden. Es handelt sich um ein vollständig präregistrierbares, randomisiertes, intenciviertes Online-Experiment.

5.1 Forschungsfrage und Hypothesen

Das Studiendesign adressiert mehrere Forschungsfragen und Hypothesen:

1. Verstärkt profitfördernder Rat die Wahl der ethisch schlechteren Kandidat:in?
H1: Profitfördernde Ratschläge erhöhen die Wahrscheinlichkeit, dass die ethisch schlechter bewertete Bewerber:in gewählt wird.
2. Unterscheidet sich die Wirkung des gleichen Rats je nach Quelle (Mensch vs. KI)?
H2: Ratschläge von KI und Mensch wirken systematisch unterschiedlich.
3. Interagieren Ratschlagsart und -quelle?
H3: Die Effektstärke der Ratschlagsart hängt von der Quelle ab.

5.2 Forschungsdesign

Das Experiment folgt einem $2 \times 2 + 1$ faktoriellen Design. Der erste Faktor ist die Quelle des Ratschlags (Mensch vs. KI), der zweite Faktor die Art des Ratschlags (ethikfördernd vs. profitfördernd). Diese Faktoren stellen die unabhängigen Variablen dar. Zusätzlich gibt es eine Baseline-Gruppe, die keinerlei Ratschlag erhält.

Die primäre abhängige Variable (AV) ist eine binäre Wahlentscheidung zwischen Ethik- und Profit-Kandidat. Zusätzlich werden sekundäre AVs erhoben (u. a. Vertrauen in die Quelle, wahrgenommene Verantwortung und ethische Normen, etc.).

Das Studiendesign gliedert sich in drei Teile: Zunächst werden Profile der kandidierenden Personen erstellt, anschließend menschliche und KI-generierte Ratschläge zu den Profilen gesammelt und schließlich wird untersucht, wie diese das Verhalten der Teilnehmenden beeinflussen. Eine Grafik zur Übersicht des Studiendesigns befindet sich im Anhang (Abb.3).

5.3 Experimentteil 1: Erstellung der Profile der kandidierenden Personen

Vor dem Hauptexperiment wird ein Pool von 5-10 Sets erstellt, von denen jedes zwei Bewerber:innen umfasst. Wie die Methodenliteratur empfiehlt, erhöht eine Variation von Stimuli die Generalisierbarkeit und verhindert, dass Effekte auf ein bestimmtes Profil zurückzuführen sind (Moshon-Cohen, Weinbach and Bitan, 2024). Die Anzahl von 5-10 Sets folgt der Empfehlung, dass zusätzliche Stimuli nur geringen zusätzlichen Nutzen bringen (Simonsohn, Montealegre und Evangelidis, 2024).

Es werden zwei Profil-Abstracts nach einheitlicher Vorlage erstellt, basierend auf realistischen Lebensläufen aus Jobportalen (Name, Kontaktdaten, Bildungsabschluss etc.). Länge und Struktur sind identisch, um Bias zu reduzieren. Die Profile unterscheiden sich nur in ethischen Attributen und profitbezogenen Merkmalen (Gehaltsvorstellungen, Berufserfahrung), während alle übrigen Aspekte konstant bleiben, um die interne Validität zu gewährleisten. Die ethische Kompetenz einer Bewerber:in wird über Hinweise auf Verantwortlichkeiten in den Bereichen Compliance, Corporate Social Responsibility (CSR) oder Ethik, durch entsprechende berufliche Positionen, Ausbildungen oder Zertifikate dargestellt. Werteorientierung und Diversität können zudem durch ehrenamtliches Engagement in NGOs oder sozialen Projekten signalisiert werden. Für die ethischen Attribute wird bewusst eine beschreibungsgestützte Darstellung statt psychometrischer Testwerte verwendet. Realistische Informationen über Bewerber:innen erhöhen die externe Validität. Solche biografischen Hinweise dienen Bewerbenden als Signale ihrer Glaubwürdigkeit und werden von Recruitern als Indikatoren für „unbeobachtbare Eigenschaften“ genutzt (Bangerter, Roulin and König, 2012). Forschung zeigt, dass viele Recruiter numerische

Werte für unzureichend halten und sich stärker auf intuitive Informationen stützen, da menschliche Eigenschaften nicht vollständig in Zahlen abbildbar sind (Highhouse, 2008).

Auf dieser Grundlage werden Profilpaare konstruiert. Ein Kandidat zeigt zahlreiche ethische Merkmale, während der andere kein Engagement aufweist. Dafür unterscheidet sich der erste in höheren Gehaltsforderungen oder geringerer Berufserfahrung. Somit variieren die Profile in moralischen und profitbezogenen Attributen, ohne dass es eine objektiv richtige Wahl gibt. Teilnehmende müssen zwischen ethischer Orientierung und ökonomischem Vorteil abwägen. Zur Sicherstellung dieser Balance wird vorab eine Pilotstudie durchgeführt, die die Attraktivität der Profile bewertet. Wird ein Profil in einem Set mit mehr als 60 % bevorzugt, werden dessen Attribute angepasst. Nach Cocks und Torgerson (2013) sollte eine Pilotstudie mindestens 9 % der geplanten Hauptstichprobe umfassen, entsprechend werden ca. 45-70 Personen befragt.

5.4 Experimententeil 2: Beratungsaufgabe

In diesem Teil werden Ratschläge von Menschen als auch von einer KI eingeholt.

5.4.1 Von Menschen verfasste Ratschläge

Da es in der Literatur keine feste Vorgabe zur Anzahl benötigter Ratschläge gibt, orientiert sich das Vorgehen an der Studie von Leib et al. (2023). Diese befragen 367 Personen, um Ratschläge zu erhalten. Für die vorliegende Studie werden HR-Professionals und Personen mit Recruiting-Erfahrung einbezogen. Da es sich um eine homogene Gruppe handelt und Leib et al. (2023) eine Erfolgsquote von 57-65% beobachten konnten, sollen etwa 150-200 Personen befragt werden. Die Rekrutierung erfolgt gezielt über LinkedIn sowie einschlägige HR-Communities (z. B. Xing-Gruppen, Slack-Communities wie HR Pioneers oder Talent Acquisition Innovators). In der Anfrage wird der Zweck und Nutzen der Studie erläutert und Incentives geboten. Berater:innen werden zudem anhand bestimmter Kriterien auf ihre Eignung geprüft (s. Anhang). Die Berater:innen verfassen Ratschläge für Recruiter und werden per Zufall entweder der ethikfördernden oder der profitorientierten Bedingung zugewiesen. Um sicherzustellen, dass die Berater:innen motiviert sind, ihre zugewiesene Aufgabe glaubwürdig umzusetzen, wird eine Anreizstruktur geschaffen. In Anlehnung an Leib et al. (2023) erhalten alle Berater:innen ein Grundhonorar von 2€. Zusätzlich erhalten sie einen Erfolgsbonus von 3€, der an die Befolgung ihres Rats durch die späteren Teilnehmer:innen gekoppelt ist:

- Bei ethikfördernden Ratschlägen, wenn die ethische Kandidat:in gewählt wird.
- Bei profitorientierten Ratschlägen, wenn die profitablere Kandidat:in gewählt wird.

Die Berater:innen erhalten zudem 10 €, wenn ihr Text die im Anhang definierten Mindestanforderungen erfüllt.