

4. KI-gestützte Hinweise und Human-in-the-Loop: Ein Studiendesign zur menschlichen Täuschungserkennung durch Expert:innen

Die Erkennung menschlicher Täuschung ist selbst für Expert:innen anspruchsvoll, da verbale, nonverbale und situative Hinweise gleichzeitig berücksichtigt werden müssen und kognitive Verzerrungen Urteile erschweren (s. Kapitel 2.1). Während Human-AI-Interaktion in vielen Bereichen gut funktioniert, stellt die Täuschungserkennung aufgrund der genannten Gründe (s. Kapitel 2) sowie einer hohen Dynamik einen Sonderfall dar. KI-gestützte Hinweise können Expert:innen bei der Täuschungserkennung unterstützen, indem sie potenziell auffällige Verhaltensmuster markieren, ohne die endgültige Entscheidungshoheit zu übernehmen, beispielsweise im Rahmen eines Human-in-the-Loop-Ansatzes (s. Kapitel 2.2). In realen Anwendungsbereichen wie dem Sicherheitsbereich, Justiz oder HR (Human Resources) sind verlässliche Urteile in komplexen Situationen erforderlich, sodass KI als Assistenzsystem hier besonders relevant sein kann. Bisherige Forschung konzentriert sich dabei jedoch vor allem auf Mensch-KI-Vergleiche, die technische Leistungsfähigkeit von KI-Systemen und die Nutzung dieser durch Laien (s. Kapitel 2.3). Währenddessen ist wenig darüber bekannt, wie Expert:innen KI-Hinweise in Täuschungsszenarien verwenden (s. Kapitel 3). Vorangegangene Studien deuten darauf hin, dass Fachpersonal in speziellen Kontexten möglicherweise eine höhere Fähigkeit zur Erkennung menschlicher Täuschung besitzt (vgl. Levine et al., 2014; O’Sullivan et al., 2009; Vrij, 2004). Das vorliegende Studiendesign setzt genau hier an.

4.1 Forschungsfrage und Hypothesen

Aufbauend auf der Grundlagenstudie von Serra-Garcia & Gneezy (2025) hat das folgende Studiendesign die Untersuchung der Nutzung von KI-gestützten Hinweisen in Täuschungskontexten durch Expert:innen zum Ziel. Dabei lautet die zentrale Forschungsfrage: Wie wirken sich Art des KI-Hinweises – kein Hinweis vs. binär vs. erklärend – und die Human-in-the-Loop-Option – vorhanden vs. nicht-vorhanden – auf Treffsicherheit, Orientierung am Hinweis und Selbstsicherheit von Expert:innen bei der Erkennung menschlicher Täuschung aus?

Aus dieser Forschungsfrage ergeben sich die folgenden beiden Hypothesen:

H1 – Hinweis-Art:

Erklärende Hinweise führen zu höherer Treffsicherheit und besserer Orientierung am Hinweis als binäre Hinweise, da Expert:innen gezielt auf relevante Signale achten können.

H2 – Human-in-the-Loop:

Wenn Expert:innen bei abweichender KI-Entscheidung die Möglichkeit erhalten, ein Video erneut anzuschauen, steigt die Treffsicherheit und die Orientierung am Hinweis wird gezielter eingesetzt.

4.2 Studiendesign und Methode

Auf Basis der zuvor formulierten Hypothesen zu Hinweis-Art (H1) und Human-in-the-Loop-Option (H2) wurde das Studiendesign so konzipiert, dass die Effekte beider Faktoren empirisch überprüfbar sind. Die experimentellen Bedingungen und Messgrößen orientieren sich an definierten Outcome-Variablen Treffsicherheit, Orientierung am Hinweis und Selbstsicherheit.

Das Experiment umfasst fünf Gruppen, welche sich in der Art des KI-Hinweises und der Verfügbarkeit einer Human-in-the-Loop-Option unterscheiden (s. Tabelle 1).

Tabelle 1: Übersicht der experimentellen Gruppen in Abhängigkeit von Hinweisart und Human-in-the-Loop-Option (Quelle: eigene Darstellung)

Art des Hinweises	Human-in-the-Loop-Option	
	Vorhanden	Nicht-vorhanden
binär	G1	G2
erklärend	G3	G4
keine (Kontrollgruppe)	G0	

Für jede Gruppe sind etwa 35–45 Expert:innen vorgesehen, sodass sich ein Gesamtumfang von rund 200 Teilnehmenden ergibt. Die Stichprobengröße basiert auf einer mittleren Effektgröße von $f \approx 0,25$, einem Signifikanzniveau von $\alpha = 0,05$ und einer gewünschten Power von 0,8, woraus eine Mindeststichprobe von $n \approx 158$ resultiert. Ein Sicherheitsaufschlag auf 200 Teilnehmende gewährleistet eine robuste Analyse.

Für das Experiment werden Expert:innen aus unterschiedlichen relevanten Berufsgruppen, darunter Polizei, Zoll, Jurist:innen und Personalverantwortliche aus dem HR-Bereich rekrutiert. Dies ermöglicht Einblicke in verschiedene Berufsgruppen, welche alltäglich mit menschlicher Täuschung konfrontiert sind. Die Teilnehmenden werden über die Plattform Prolific sowie Fachverbände angesprochen, wobei sich Filterkriterien hierzu im Anhang auf Seite 14 finden. Eine Teilnahme wird pauschal mit 20–30 € vergütet, um sicherzustellen, dass die Expert:innen unabhängig vom Entscheidungsergebnis sorgfältig urteilen. Zudem wird das Experiment als Online-Studie durchgeführt, um genügend Expert:innen rekrutieren zu können.

Der Ablauf der Studie gliedert sich in drei Abschnitte (s. Abbildung 3): einen kurzen Pretest, das Hauptexperiment und einen abschließenden Posttest. Der Pretest dient dazu, zentrale demografische Merkmale, berufliche Hintergründe, einschlägige Erfahrung mit Täuschungssitu-

ationen, Kompetenz- und Eignungseinschätzungen sowie potenzielle Kontrollvariablen zu erfassen und gleichzeitig sicherzustellen, dass nur geeignete Teilnehmende gemäß den definierten In- und Exklusionskriterien in die Studie eingeschlossen werden. Im Hauptteil der Untersuchung werden die Expert:innen dazu angehalten, sich 20 Videoclips aus der Fernsehshow *Golden Balls*, wie in der Studie von Serra-Garcia & Gneezy (2025) anzuschauen. Jede:r Expert:in trifft nach Ansicht eines Videos eine Einschätzung darüber, ob die gezeigte Person Täuschung zeigt („ja/nein“), und bewertet die eigene Sicherheit der Entscheidung auf einer siebenstufigen Likert-Skala. Anschließend wird ein KI-Hinweis präsentiert, welcher entweder binär („wahrscheinlich ehrlich/wahrscheinlich unehrlich“) oder erklärend mit kurzer Begründung und Angabe relevanter Signale versehen ist. Die Human-in-the-Loop-Option kommt nur dann zum Einsatz, wenn die Expert:innen Entscheidung vom KI-Hinweis abweicht. In diesem Fall kann der Videoclip erneut angesehen werden, um die Entscheidung zu bestätigen oder anzupassen. Abschließend ist zu erwähnen, dass ein hybrides Design für die Auswahl der Videos gewählt wird. Dabei sind die ersten zehn Videos für alle Teilnehmenden identisch und die zweiten zehn werden randomisiert aus dem Gesamtpool bestimmt, um sowohl Vergleichbarkeit als auch Generalisierbarkeit sicherzustellen. Ein abschließender Posttest erfasst erneut eine Selbsteinschätzung und wird um Fragen zur Orientierung an und Nutzung der KI-Hinweise und zur Human-in-the-Loop-Option ergänzt, um Veränderungen gegenüber dem Pretest sichtbar zu machen. Eine Ausarbeitung von Pre- und Posttest findet sich im Anhang auf den Seiten 15-18.

4.3 Geplante Datenanalyse

Die Daten werden mit Mixed-Effects-Modellen analysiert, um die hierarchische Struktur der Studie zu berücksichtigen. Feste Effekte sind dabei die experimentellen Faktoren wie Hinweis-Art, Human-in-the-Loop-Option sowie relevante Kontrollvariablen wie Erfahrung und Vorwissen. Diese Effekte geben Aufschluss darüber, wie sich die Bedingungen systematisch auf Treffsicherheit, Orientierung an den Hinweisen und Selbstsicherheit auswirken. Zufällige Effekte erfassen die individuellen Unterschiede zwischen Teilnehmenden und die Unterschiede zwischen den Videos, sodass die Modelle die natürliche Variabilität innerhalb der Stichprobe und der Videos berücksichtigen. Treffsicherheit wird als binäre Variable mit einem logistischen Mixed-Effects-Modell analysiert. Orientierung, Selbstsicherheit und Pre-Post-Veränderungen über lineare Mixed-Effects-Modelle. Zusätzlich werden explorativ Änderungen nach abweichendem KI-Hinweis und Vergleiche zur Kontrollgruppe betrachtet, während Freitextantworten aus dem Posttest inhaltsanalytisch ausgewertet werden. Dieses Vorgehen ermöglicht es, die Effekte der experimentellen Bedingungen und individuelle Unterschiede zuverlässig zu erfassen.

5. Diskussion

Im folgenden Kapitel wird das Studiendesign kritisch reflektiert, indem methodisches Vorgehen sowie zentrale Limitationen aufgezeigt werden. Weiter werden praktische Implikationen sowie Ansätze für zukünftige Forschung an der Schnittstelle von menschlicher Täuschungserkennung und algorithmischer Assistenz diskutiert.

5.1 Kritische Diskussion des Studiendesigns und potenzielle Limitationen

Aufbauend auf der Grundlagenstudie wird im vorliegenden Design bewusst ein nachgelagerter Hinweis eingesetzt. Zwar zeigte sich in der Grundlagenstudie, dass Hinweise vor einer Entscheidung stärker genutzt werden, jedoch entspricht der nachgelagerte Hinweis eher realen Anwendungsszenarien im professionellen Kontext. Dabei handelt es sich beispielsweise um Befragungen oder Interviews, in denen Expert:innen zunächst eigenständig eine Entscheidung treffen müssen. Zugleich soll verhindert werden, dass der KI-Hinweis die ursprüngliche Urteilsbildung unmittelbar verzerrt. Insbesondere bei erfahrenen Expert:innen ist davon auszugehen, dass deren Expertise eine unabhängige Erstentscheidung ermöglicht, welche anschließend durch KI-Hinweise reflektiert werden kann. Darauf basierend adressieren die gewählten Hinweisformate unterschiedliche Bedürfnisse. Binäre Hinweise sind schnell generierbar, übersichtlich und beeinflussen bereits gebildete Urteile nur moderat, während erklärende Hinweise konkrete Indikatoren aufzeigen und die gezielte Nutzung dieser unterstützen. Unter der Human-in-the-Loop-Option können Expert:innen in beiden Fällen ihr Urteil überprüfen und bei abweichendem KI-Hinweis anpassen, wobei erklärende Hinweise eine detailliertere Unterstützung bieten. Gleichzeitig sind diese im Experiment zeitaufwendiger und bergen das Risiko einer Überorientierung auf bestimmte Aspekte. Studien zeigen jedoch, dass Menschen KI zur Entscheidungsunterstützung besonders effektiv nutzen, wenn Hinweise nachvollziehbar sind (vgl. Senoner et al., 2024). Weiter wirkt der erklärende Hinweis häufig verwendeten Black Box Modellen entgegen (vgl. Suchotzki & Gamer, 2024) und erhöht sowohl Transparenz als auch Nachvollziehbarkeit KI-gestützter Systeme.

Die Entscheidung, die Videoclips aus der Fernsehshow erneut zu nutzen, bietet zwar Vorteile hinsichtlich Ethik und Datenschutz, da reale Täuschungssituationen ohne personenbezogene Daten einsetzbar sind, führt jedoch zu Einschränkungen der ökologischen Validität. Täuschungen in Fernsehshows unterscheiden sich deutlich von solchen in polizeilichen, juristischen oder personalpsychologischen Kontexten. Sie sind weniger risikobehaftet und entstehen unter künstlich stabilen Bedingungen, wie hochwertigem Licht und Ton. Diese können die Erkennungsaufgabe sowohl für Menschen als auch für KI erleichtern. In realen Interaktionen

hingegen variieren Blickrichtungen, Gesprächsverläufe, Motivlagen und emotionale Belastungen erheblich. Diese in der vorliegenden Untersuchung nicht abgebildete Dynamik könnte zu stark veränderten Ergebnissen führen (vgl. Avdal Saleh & Sedqi Kareem, 2025; Markowitz & Levine, 2025). Die Ergebnisse sind somit als erste Orientierung zu betrachten.

Ein weiterer methodischer Engpass liegt in der fehlenden Interaktivität. Täuschungserkennung beruht im beruflichen Alltag wesentlich auf dialogischen Prozessen, etwa auf Rückfragen, und der Anpassung an Reaktionen. Zudem gibt es empirische Evidenz dafür, dass Lügenerkennungsquote von Expert:innen besonders hoch sind, wenn sie potenzielle Lügende aktiv befragen dürfen (vgl. Levine et al., 2014). Die reine Video-Beurteilung bildet diese Prozesse nicht ab und erlaubt somit nur begrenzte Rückschlüsse auf reales professionelles Entscheidungsverhalten. Auch wenn die Spielshow klar vorgibt, was wahr oder falsch ist, sind diese Prüfungen nicht mit den komplizierten, motivationsgetriebenen Lügen in realen Lebenssituationen vergleichbar. Für das Training von KI-Modellen für reale Anwendungsfelder ist diese eingeschränkte Übertragbarkeit besonders relevant.